



Analisis Cluster



Konsep dasar



- *Cluster Analysis* adalah salah satu analisis data eksplorasi di mana pengamatan dibagi menjadi beberapa **kelompok berbeda** yang memiliki **karakteristik yang sama**.
- **Tujuan** analisis klaster adalah untuk membangun kelompok/kelas/klaster dengan memastikan bahwa: dalam **satu kelompok pengamatan harus semirip mungkin** (*intracluster similarity*), sedangkan **antar kelompok pengamatan sebisa mungkin berbeda** (*intercluster dissimilarity*).




Image source: [Stats and R](#)

Konsep dasar



What is these people's similarity?



Introverts

What about this?



Extroverts



What is their intercluster dissimilarity?

//////

Konsep dasar (2)




- Aplikasi Clustering sangat luas, mencakup berbagai bidang, misal: *business intelligence, image pattern recognition, Web search, biologi, security* dll.
- Kegunaan clustering:
 - **Data mining:** analisis klaster dapat digunakan sebagai alat untuk mendapatkan mengetahui sebaran data, mengamati karakteristik setiap cluster, dan untuk fokus pada satu set tertentu dari cluster untuk dianalisis lebih lanjut.
 - **Data segmentation:** mempartisi kumpulan data besar ke dalam grup berdasarkan kemiripannya
 - **Outlier detection:** digunakan jika outlier (nilai yang "jauh" dari cluster) mungkin lebih menarik daripada kasus umum.
- Clustering dikenal sebagai **unsupervised learning** karena informasi label kelas tidak tersedia. Untuk alasan ini, clustering adalah bentuk *learning by observation*, bukan *learning by examples*.



Syarat Analisis Klaster

- clustering hanya pada sampel dari sekumpulan data besar dapat menyebabkan hasil yang bias. Oleh karena itu, sangat diperlukan algoritma clustering yang *highly scalable*.
- Mampu menangani berbagai jenis atribut.
- Mampu menemukan cluster dengan bentuk arbitrer: sebuah cluster bisa dalam bentuk apapun. Algoritma berdasarkan Euclidean/Manhattan distance cenderung hanya menemukan spherical clusters.
- Mensyaratkan *domain knowledge* untuk menentukan parameter input.
- Mampu menangani *noisy data* (eg.: outliers, missing, unknown, or erroneous data).
- Mampu mengakomodir clustering tambahan dan tidak sensitif terhadap urutan input.
- Mampu mengelompokkan data berdimensi tinggi.
- *Constraint-based clustering*: tantangannya adalah menemukan grup data dengan perilaku pengelompokan yang baik yang memenuhi batasan yang ditentukan.
- Hasil pengelompokan dapat ditafsirkan, dipahami, dan dapat digunakan.

Ukuran jarak



Memilih ukuran jarak merupakan langkah penting dalam clustering karena menentukan hasil akhir pengklasteran. Berikut adalah **2 metode klasik** untuk mengukur jarak:

1. *Euclidean distance:*

$$d_{euc}(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$$

2. *Manhattan distance:*

$$d_{man}(x, y) = \sum_{i=1}^n |(x_i - y_i)|$$

Dengan x dan y merupakan 2 vector berukuran n . Kedua ukuran jarak di atas dapat dihitung fungsi **dist()** di R base.



Ukuran jarak lainnya

Correlation-based distances (`get_dist()` [factoextra package])



3. Pearson correlation distance:

Korelasi Pearson mengukur derajat hubungan linier antara dua variable.

$$d_{cor}(x, y) = 1 - \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}}$$

4. Eisen cosine correlation distance (Eisen et al., 1998):

Bentuk khusus dari korelasi Pearson dengan nilai $\bar{x}$ dan $\bar{y}$ diganti dengan 0.

$$d_{eisen}(x, y) = 1 - \frac{\left| \sum_{i=1}^n x_i y_i \right|}{\sqrt{\sum_{i=1}^n x_i^2 \sum_{i=1}^n y_i^2}}$$

5. Spearman correlation distance:

Korelasi spearman mengukur derajat hubungan antara ranking variable x dan y.

$$d_{spear}(x, y) = 1 - \frac{\sum_{i=1}^n (x'_i - \bar{x}')(y'_i - \bar{y}')}{\sqrt{\sum_{i=1}^n (x'_i - \bar{x}')^2 \sum_{i=1}^n (y'_i - \bar{y}')^2}}$$

6. Kendall correlation distance:

Korelasi Kendall mengukur korespondensi antara rangking variable x dan variabel y.

$$d_{kend}(x, y) = 1 - \frac{n_c - n_d}{\frac{1}{2}n(n-1)}$$

Dimana, n_c : total number of concordant pairs, n_d : total number of discordant pairs, n : size of x and y

////// Tipe jarak mana yg dipilih?



- Software statistik untuk clustering umumnya menggunakan jarak Euclidean secara default.
- Pemilihan tipe jarak prinsipnya tergantung pada jenis data dan pertanyaan penelitian. Contoh: jarak berbasis korelasi sering digunakan dalam analisis data ekspresi gen.
- Jarak berbasis korelasi menganggap dua objek serupa jika fitur-fiturnya berkorelasi tinggi, meskipun nilai-nilai yang diamati mungkin berjauhan jika dihitung dengan jarak Euclidean. Jarak antara dua objek adalah 0 ketika keduanya berkorelasi sempurna.
- Jika kita ingin mengidentifikasi kluster dari observasi yang memiliki profil keseluruhan yang sama, terlepas berapa besarannya, maka sebaiknya kita gunakan jarak berbasis korelasi.
- Jika jarak Euclidean yang dipilih, maka observasi-observasi bernilai fitur tinggi akan berada dalam cluster yang sama. Demikian pula untuk observasi-observasi dengan nilai fitur yang rendah.






HIERARCHICAL MODELS

Pendahuluan



- Mengelompokkan objek data ke dalam suatu hirarki atau “pohon” klaster
- Dibagi menjadi dua tipe: *agglomerative* dan *divisive*



HIERARCHICAL MODELS

Agglomerative Nesting (AGNES) vs Divisive Analysis (DIANA)


AGNES – BOTTOM UP

AGNES


Pengelompokkan dimulai dari setiap individu dianggap sebagai kluster tersendiri, lalu secara *iterative* tiap individu akan bergabung dengan individu lain yang mirip, hingga akhirnya semua individu menjadi satu kluster

DIANA

Pengelompokkan dimulai dari semua individu tergabung sebagai satu kluster, kemudian secara *iterative* terpisah-pisah menjadi kelompok-kelompok yang lebih kecil



DIANA – TOP DOWN





HIERARCHICAL MODELS

● *Algoritma*



1. Siapkan data
2. Hitung jarak dis(similarity) antar objek
3. Gunakan fungsi *linkage* untuk mengelompokkan objek menjadi pohon klaster hirarki berdasarkan jarak yang sudah dihitung. Objek/klaster yang berjarak dekat dikelompokkan bersama dengan menggunakan fungsi *linkage*
4. Visualisasi dendogram dan tentukan dimana akan memotong “pohon” untuk membuat klaster



HIERARCHICAL MODELS

• Fungsi Linkage



1. **Complete Linkage**: Jarak antara 2 klaster menggunakan nilai maksimum dari semua kombinasi jarak antara elemen di kluster 1 dan elemen di kluster 2.
2. **Single Linkage**: Jarak antara 2 klaster menggunakan nilai minimum dari semua kombinasi jarak antara elemen-elemen di kluster 1 dan elemen-elemen di kluster 2.
3. **Average Linkage**: Jarak antara 2 klaster menggunakan rata-rata antara elemen-elemen di kluster 1 dan elemen-elemen di kluster 2.
4. **Centroid Linkage**: Jarak antara 2 klaster menggunakan jarak centroid/pusat kluster 1 dan kluster 2.
5. **Ward's**: meminimumkan variasi total dalam klaster. Pada setiap tahap, pasangan klaster dengan jarak antara klaster minimum akan digabung.




HIERARCHICAL MODELS

Dendrogram



- Visualisasi yang menggambarkan pengelompokan “pohon” hirarki



```
# cex: label size  
library("factoextra")  
fviz_dend(res.hc, cex = 0.5)
```

Q: Mau potong dimana?

Dibagi 2 klaster

Dibagi 4 klaster



PARTITIONING MODEL

- *K-means clustering*
- *K-medoids or PAM (Partitioning Around Medoids)*
- *Clustering Large Applications (CLARA)*

K-Means Clustering

Konsep dasar



- **K-means clustering** pada dasarnya mendefinisikan sejumlah cluster sehingga total variasi intra-cluster (*total within-cluster variation*) diminimalkan.
- Ada beberapa algoritma k-means yang tersedia. Algoritma standarnya adalah milik Hartigan-Wong (1979), yang mendefinisikan variasi total dalam cluster sebagai jumlah kuadrat jarak Euclidean antara item dan centroid yang bersesuaian.

$$tot.withinss = \sum_{k=1}^k W(C_k) = \sum_{k=1}^k \sum_{x_i \in C_k} (x_i - \mu_k)^2$$

- Setiap pengamatan x_i ditetapkan pada cluster tertentu sedemikian rupa sehingga jumlah kuadrat (SS) jarak pengamatan ke pusat cluster yang ditetapkan μ_k semiminal mungkin.



K-Means Clustering

Algoritma K-means



1. Tentukan jumlah cluster (**K**) yang akan dibuat (oleh analyst)
2. Algoritma memilih secara acak objek sebanyak k dari dataset sebagai pusat cluster awal (disebut juga *means/centroids*)
3. *Assignment step* □ Menetapkan setiap pengamatan ke centroid terdekat berdasarkan jarak Euclidean. Note: jika ingin digunakan jarak berbasis korelasi, data perlu diinput dalam skor-z
4. *Centroid update* □ Memperbarui centroid untuk setiap cluster dengan menghitung nilai rata-rata yang baru dari semua titik data dalam cluster.
5. Secara berulang meminimalkan total dalam jumlah kuadrat. Artinya, algoritma akan mengulangi langkah 3 dan 4 sampai penetapan cluster berhenti berubah atau jumlah maksimum iterasi tercapai. Secara default, software R menggunakan nilai 10 sebagai jumlah iterasi maksimum.



K-Means Clustering

Algorithm K-means



ITERATION 1

<https://halderadhika91.medium.com/k-means-clustering-understanding-algorithm-with-animation-and-code-6e644993afab>

K-Means Clustering



Kelebihan:

- Algoritmanya sangat sederhana dan sangat cepat.
- Efisien dalam menangani dataset yang besar.

Kekurangan:

- Metode ini mengasumsikan *prior knowledge* tentang data dan mengharuskan analis untuk memilih jumlah cluster (k) yang sesuai terlebih dahulu.
Solusi: Hitung k-means untuk rentang nilai k , misalnya dengan memvariasikan k antara 2-10. lalu pilih k terbaik dengan membandingkan hasil clustering yang nilai k yang berbeda.
- Hasil akhir yang diperoleh sensitif terhadap pemilihan acak inisial pusat cluster. Hal ini dapat menyebabkan hasil clustering yang berbeda meski algoritma dijalankan pada dataset yang sama.
*Solusi: Jalankan algoritma K-means beberapa kali dengan inisial pusat cluster yang berbeda. Proses run dengan total *within-cluster sum of square* terendah akan terpilih sebagai solusi final clustering.*
- Sensitif terhadap outlier
Solusi: gunakan algoritma PAM (akan dibahas pada slide berikutnya).
- Sensitif terhadap perubahan urutan (order) data.



K-Means Clustering

Kekurangan



K-medoids (PAM)



- Istilah **medoid** mengacu pada objek dalam sebuah cluster yang memiliki rata-rata perbedaan paling kecil terhadap semua anggota cluster lainnya, i.e **titik paling sentral dalam cluster**. Medoids ini (satu per cluster) dapat dianggap sebagai **contoh representatif** dari anggota cluster.
- *K-medoids* adalah alternatif yang lebih **robust** dari *k-means clustering*. Artinya, algoritma ini relatif tidak sensitif terhadap noise dan outlier dibandingkan dengan k-means, karena menggunakan *medoid* sebagai pusat cluster alih-alih rata-rata.
- Metode clustering k-medoid yang paling umum adalah dengan **algoritma PAM** (Partitioning Around Medoids, Kaufman & Rousseeuw, 1990)

K-medoids (PAM)



- Secara ringkas, algoritma PAM dijelaskan sebagai berikut:
 1. Pilih k objek untuk menjadi medoid, atau jika disediakan gunakan objek tersebut sebagai medoid;
 2. Hitung matriks dissimilarity jika tidak tersedia;
 3. Tetapkan setiap objek ke medoid terdekatnya;
 4. Untuk setiap pencarian kluster cari jika salah satu objek kluster menurunkan koefisien ketidaksamaan rata-rata; pilih entitas yang paling banyak menurunkan koefisien tersebut sebagai medoid untuk cluster yang bersesuaian;
 5. Jika setidaknya satu medoid telah berubah, ulangi langkah (3), jika tidak, akhiri algoritma.
- Algoritma PAM dijalankan dengan matriks dissimilarity, untuk menghitungnya dapat digunakan dua pilihan ukuran: Euclidean dan Manhattan distances.
- Dalam praktiknya, seringkali penggunaan kedua ukuran jarak tersebut memberikan hasil yang serupa. Namun jika data mengandung outlier, jarak Manhattan dapat memberikan hasil yang lebih robust dibanding Euclidean.

K-medoids (PAM)

Required R packages and functions



- Untuk menjalankan algoritma PAM, dapat digunakan function ***pam()*** [**cluster package**] and ***pamk()*** [**fpc package**]. (Note: *pamk()* tidak memerlukan spesifikasi jumlah cluster K oleh user)

```
pam(x, k, metric = "euclidean", stand = FALSE)
```

Output dari fungsi ***pam()*** meliputi::

- *medoids*: Objek-objek yang mewakili clusters
 - *clustering*: sebuah vector yang memuat nomor cluster dari setiap objek
- Untuk membuat grafik menarik dari cluster yang dihasilkan dengan fungsi *pam()*, gunakan package ***factoextra*** dengan format ***fviz_cluster(pam.res)***
 - Perhatikan bahwa, untuk dataset yang besar, *pam()* mungkin memakan banyak memori atau waktu komputasi. Dalam hal ini, fungsi *clara()* lebih disukai. Namun seharusnya tidak menjadi masalah bagi pengguna komputer modern.


CLARA



- CLARA (**Clustering Large Applications**, Kaufman dan Rousseeuw (1990)) merupakan ekstensi dari metode k-medoids untuk menangani data yang berisi objek dalam jumlah besar untuk mengurangi waktu komputasi dan masalah penyimpanan RAM.
- Alih-alih menemukan medoid untuk keseluruhan dataset, CLARA mempertimbangkan sampel kecil dari data dengan ukuran fixed (sampsiz) dan menerapkan algoritma PAM untuk menghasilkan satu set medoid yang optimal untuk sampel tersebut.
- Ringkasan algoritma CLARA:
 1. Split dataset secara acak dalam beberapa subset dengan ukuran fixed (sampsiz)
 2. Jalankan algoritma PAM pada setiap subset dan pilih sebanyak k objek representatif (medoid) yang sesuai. Tetapkan setiap pengamatan dari seluruh dataset ke medoid terdekat.
 3. Hitung rata-rata (atau jumlah) dari ketidaksamaan pengamatan terhadap medoid terdekatnya. Ukuran ini digunakan sebagai ukuran *goodness of clustering*.
 4. Pertahankan sub-dataset yang rata-rata (atau jumlah)-nya minimal. Analisis lebih lanjut dilakukan pada partisi terakhir.



Estimasi Jumlah Cluster Optimal




Estimasi Jumlah Cluster Optimal



1. Elbow method

Metode ini melihat nilai total jumlah kuadrat dalam cluster (within-cluster sum of square/WSS) sebagai fungsi dari jumlah cluster.



```
# load required packages  
library(factoextra)  
library(NbClust)
```

```
# Elbow method  
fviz_nbclust(Eurojobs, kmeans, method = "wss") +  
  geom_vline(xintercept = 4, linetype = 2) + # add line for better visualisation  
  labs(subtitle = "Elbow method") # add subtitle
```


Lokasi elbow di plot biasanya dianggap sebagai indikator jumlah cluster yang sesuai karena itu berarti menambahkan cluster lain tidak meningkatkan partisi yang jauh lebih baik. Metode Elbow terkadang ambigu dan alternatifnya adalah Average silhouette method.

Estimasi Jumlah Cluster Optimal



2. Average silhouette method

Metode Silhouette mengukur kualitas pengelompokan dan menentukan seberapa baik setiap titik terletak di dalam klasternya. Metode ini menghitung average silhouette pengamatan untuk berbagai nilai k.



```
# load required packages
```

```
library(factoextra)
```


```
library(NbClust)
```

```
# Silhouette method
```

```
fviz_nbclust(Eurojobs, kmeans, method = "silhouette") +  
  labs(subtitle = "Silhouette method")
```

Jumlah optimal cluster k adalah nilai k yang memaksimalkan nilai *average silhouette* pada kisaran nilai yang mungkin untuk k (Kaufman dan Rousseeuw [1990]).

Estimasi Jumlah Cluster Optimal




3. Gap statistic method

Pendekatan ini dapat diterapkan pada metode clustering apa pun. Statistik ini membandingkan total dalam variasi intra-cluster untuk nilai k yang berbeda dengan nilai ekspektasi di bawah distribusi referensi nol dari data.

Optimal number of clusters

Gap statistic method



```
# load required packages
library(factoextra)
library(NbClust)
# Gap statistic
set.seed(42)
fviz_nbclust(Eurojobs, kmeans,
  nstart = 25,
  method = "gap_stat",
  nboot = 500
) +
  labs(subtitle = "Gap statistic method")
```

Nilai k yang memaksimalkan gap statistic (atau yang menghasilkan gap statistics yang terbesar) merupakan estimasi jumlah cluster optimal.



ADVANCED CLUSTERING METHODS

Advanced clustering methods



❖ ***Hierarchical k-means clustering***

Merupakan pendekatan hybrid untuk memperbaiki hasil clustering dengan K-Means. Fungsi `hkmeans()` di package `[factoextra]`, memberikan solusi mudah untuk clustering dengan metode ini. pengelompokan k-means hierarkis.

❖ ***Fuzzy clustering***

Fuzzy clustering dianggap sebagai *soft clustering*, alternatif dari k-means clustering dimana setiap titik data memiliki koefisien keanggotaan untuk setiap cluster. Dengan metode ini, titik-titik yang dekat dengan pusat cluster, mungkin berada di cluster dengan derajat yang lebih tinggi dibandingkan titik-titik di tepi cluster. Derajat, di mana suatu elemen milik cluster tertentu berupa nilai numerik yang bervariasi dari 0 hingga 1. Algoritma fuzzy c-means (FCM) adalah salah satu dari algoritma fuzzy clustering yang paling banyak digunakan. Fungsi `fanny()` [cluster R package] dapat digunakan untuk fuzzy clustering. FANNY singkatan dari *fuzzy analysis clustering*.

Advanced clustering methods



❖ ***Model-based clustering***

Pada clustering berbasis model, data dipandang berasal dari distribusi yang merupakan campuran dua atau lebih cluster. Metode ini mencari model yang paling cocok dengan data dan memperkirakan jumlah cluster. *Model-based clustering* dapat diterapkan pada univariate maupun multivariate dan dilakukan dengan menggunakan fungsi `Mclust()` pada package `[mclust]`.

❖ ***DBSCAN: Density-Based Clustering***

The density-based clustering (DBSCAN merupakan metode clustering yang diperkenalkan dalam Ester et al. (1996). Metode ini dapat mengidentifikasi cluster dalam berbagai bentuk (tidak harus lingkaran) dan ukuran dari data yang mengandung noise dan outlier. Keunggulan lainnya adalah, tidak seperti K-means, DBSCAN tidak mengharuskan pengguna untuk menentukan jumlah cluster yang akan dihasilkan. Metode clustering ini dapat dilakukan di R dengan package `[fpc]` atau `[dbscan]`.



Metode Klaster Lainnya

❖ ***K-mode Algorithm (Huang, 1997)***

Algoritma ini bertujuan untuk mempartisi objek menjadi k grup sehingga jarak dari objek ke modus klaster dapat diminimalkan. Di R, kita menggunakan package klaR.

<https://cran.r-project.org/web/packages/klaR/klaR.pdf>

❖ ***K-prototype Algorithm***

Algoritma K-Prototype adalah pengembangan dari algoritma k-Modes yang menggabungkan algoritma k-modes and k-means sehingga mampu mengelompokkan data numerik dan kategori. Di R, menggunakan package clustMixType

<https://cran.r-project.org/web/packages/clustMixType/clustMixType.pdf>


❖ ***Ensemble clustering***

ini mengacu pada situasi ketika sejumlah pengelompokan yang berbeda telah diperoleh untuk kumpulan data tertentu dan diinginkan untuk menemukan pengelompokan (konsensus) tunggal yang lebih cocok dalam beberapa hal daripada pengelompokan yang ada.


Di R, menggunakan package diceR

<https://cran.r-project.org/web/packages/diceR/diceR.pdf>

Advanced clustering methods



K-means



DBSCAN



THANKS